


Agentic AI in der Praxis

Vom Auftrag zur produktiven Arbeitsweise, mit Übungen am eigenen Rechner

Illustrations AI-generated · Flux 2 (flux2-dev)



Über uns und zwei Beispiele

Christian Uhl · ZAD, Uni Gießen

- Unbekannter Chip ohne Firmware
- Ein einzelner Fehler hätte ihn zerstört
- Sorgfältig war zu langsam, schnell zu riskant
- Nach 24 Stunden: FIDO2-Firmware, spec- und testgetrieben

Tobias Weiß · DevOps, Uni Marburg

- openDesk Edu: Dienste für Forschung, Lehre, Verwaltung
- Wissens-Pipelines und IT-Betrieb agentisch
- Open-Source-Software mit Open-Source-Werkzeugen

Ihre Reihe: Blitzlicht in dreißig Sekunden pro Person

- Name, Fachrichtung, ein Thema für eine Literaturrecherche
- Selbsteinschätzung KI: eher Anfang oder eher fortgeschritten?
- Wir sammeln die Wünsche am Whiteboard
- Am Ende prüfen wir sie gegen die Outcomes

Tobias

Der Vormittag liefert ein Werkzeug, keinen fertigen Bot

- Ein Research-Repo mit laufender Pipeline
- Einen prüfbaren Auftrag, live umgesetzt
- Werkzeuge für Modelle und Harnesses statt Trendlisten
- Nicht dabei: der voll-autonome Assistent

Tobias

Bis zur ersten Pause: Grundlagen, Modelle, Werkzeuge

Block

Ankommen, Vorstellung, Blitzlicht

Grundlagen: Agenten beauftragen

Foundation Models: aktuelle Entwicklungen

Open-Source Toolbox

☹ Pause 10:10 bis 10:20

Tobias

Danach zweimal selbst ausprobieren, dazwischen der Weg zur Spezifikation

Block

Hands-On: Erste Schritte, direkt agentisch

Vom Auftrag zur Spezifikation, und was sie an Token spart

Hands-On: Mit Spec

☕ Pause 11:25 bis 11:30

Outcomes: Ihre Ergebnisse

Ihre Anwendungsfälle, Q&A, Diskussion

Christian

1


Grundlagen: worüber wir sprechen

Bei diesen fünf Begriffen legen wir uns für heute fest


Begriff	Worüber gestritten wird	Unsere Festlegung
Agent	von Chatbot bis autonomes System	Das Modell bestimmt die nächsten Schritte
Reasoning	ob das Denken ist	mehr Rechenzeit zur Laufzeit
Halluzination	Begriff umstritten, eher Konfabulation	unbelegte Ausgabe, Grund für die Tests
Open Weights	Gewichte offen, Rest oft nicht	Lizenzen getrennt prüfen
Reproduzierbarkeit	gleiche Eingabe, anderes Ergebnis	Stand sichern, Analyse wiederholen

Ein agentisches System besteht aus vier Bausteinen

- Modellwissen ist keine Datenbank
- Kontext ist Arbeitsgedächtnis
- Werkzeuge nur, soweit freigegeben
- Das Harness setzt Grenzen



Wer einen Agenten aufbaut, legt vier Dinge fest



- Instruktionen: AGENTS.md, verweisen auf Skills
- Skills: Anleitungen zum Nachschlagen
- Trigger: Befehl, Zeitplan oder Ereignis
- Capabilities legen fest, was er darf

Christian

The screenshot shows the 'Build' tab of an AI agent configuration interface. It contains five main sections: 'Model', 'Instructions', 'Skills', 'Triggers', and 'Capabilities'. The 'Model' section has a dropdown menu set to 'qwen38-flash-next' under the 'OpenAI account'. The 'Instructions' section has a text input with the value 'Summarize new tickets in the Customer Support Slack channel.' The 'Skills' section has a text input with the value 'Add skill'. The 'Triggers' section has a text input with the value 'Add channel' and a 'Preview' button. The 'Capabilities' section has a text input with the value 'Add tool' and a 'Web search' toggle set to 'Off'.

Build Knowledge Sessions Settings

Model *
What model this agent uses
qwen38-flash-next OpenAI account

Instructions *
What this agent should do
Summarize new tickets in the Customer Support Slack channel.

Skills
How this agent handles specific tasks
Add skill

Triggers
Where and when this agent runs
Add channel
Add schedule
Preview

Capabilities
What this agent can do and how it does it
Add tool
Add workflow
Add sub-agent

Web search
Let the model search the web when it needs up-to-date information.
Off

Auch Agents as a Service brauchen genau diese vier Dinge

Christian


Ein Skill ist eine Anleitung, die das Modell selbst nachschlägt

- Ein Ordner mit SKILL.md: Name, Beschreibung, Anleitung
- Im Kontext steht anfangs nur die Beschreibung
- Das Modell entscheidet, wann es nachliest
- Offener Standard, läuft in OpenCode und pi
- Fremde Skills vorher lesen, sie können Code ausführen

Wo wir Agenten heute schon begegnen

Wo	Beispiel	Der Agent entscheidet selbst
Recherche	Deep Research in Gemini, ChatGPT	welche Quelle er als Nächstes liest
Büro	Copilot Researcher in M365	was er in Mails und Dateien sucht
Browser	Claude in Chrome, Comet	wohin er klickt, was er einträgt
Zuhause	Alexa+	welchen Dienst er für eine Buchung nutzt
Forschung	Elicit, Google Co-Scientist	wie er eine Forschungsfrage zerlegt
Software	Claude Code, Codex, Copilot	welche Datei er ändert, was er testet

Christian



Beispiel: Claude Cowork

Christian

2

Wie man einen Agenten beauftragt

Fragen oder Beauftragen



- Fragen: „Fassen Sie diese Papers zusammen.“
- Beauftragen: „Extrahieren Sie diese fünf Felder aus jedem Paper.“

Ein prüfbarer Auftrag hat drei Ebenen

- Jede Ebene ist eine Datei, kein Gespräch
- Der Vertrag ist eine Spezifikation für eine Änderung
- Der Vertrag nennt das Kriterium, der Test wendet es an



Jede der drei Ebenen legt etwas anderes fest

Ebene	Legt fest	Im Repository
Spezifikation	was gelten soll, prüfbar formuliert	specs/, AGENTS.md
Vertrag	was sich jetzt ändert, und woran man es misst	ein Change mit Vorschlag und Aufgaben
Tests	ob die geprüften Fälle bestehen	Testsuite, Validierung, CI

Christian



**Erledigt ist eine Aufgabe erst,
wenn die Prüfung bestanden ist.**

Christian

3

Foundation Models: aktuelle Entwicklungen

Sechs Entwicklungen prägen die Modelle im Jahr 2026

- Reasoning ist reif: planen statt vervollständigen
- Kontext wächst von 200.000 auf über eine Million Token
- MCP wird der Standard für Werkzeugzugriff
- Werkzeugaufrufe sind produktionsreif
- Offene Gewichte holen auf, die Kosten fallen
- Lokal und souverän betreiben ist eine echte Option

Christian


Unsere Modellwahl im Alltag

Aufgabe	Unsere Wahl	Einordnung
Freie Texte, Übersetzung	GPT-6	bewährt in unseren Schreibaufgaben
Vision	GPT-6, Claude Fable 5	Fable 5 führt die Arena Vision
Code, größere Umbauten	Claude Opus 5.5, zunehmend GLM	bei uns oft wenige Korrekturen
Code gezielt umschreiben	Qwen3.8-Flash-Next, GLM	offene Gewichte, schnell, günstig
Abläufe mit Werkzeugen	GLM 5.3 Flash, Claude Sonnet 5.5	verlässliche Werkzeugaufrufe
Sensible Forschungsdaten	Qwen3.8 27B, lokal via vLLM	die Daten verlassen das Haus nicht
Viele gleichartige Fälle	DeepSeek V4.1 Flash	Geschwindigkeit und Kosten entscheiden

Christian

Das Harness bestimmt, was das Modell erreichen kann

- Modell und Kontext prägen die Antwort
- Das Harness begrenzt die Ausführung
- Das Modell schlägt nächste Schritte vor
- Gutes Harness kann Modellschwächen ausgleichen




Tobias

4

Open-Source Toolbox: Harnesses als Steuerungsebene

Agentisch ist nicht das Terminal, sondern die Autonomie



- Auch eine GUI kann agentisch sein
- Autonomie heißt: delegierte Befugnisse
- CI automatisiert, sie entscheidet nicht selbst

Tobias

Der Agent arbeitet, die Verantwortung bleibt bei Ihnen

- Sie verstehen, was der Agent getan hat
- Sie geben frei, der Agent schlägt nur vor
- Geht etwas schief, stehen Sie dafür ein
- Ungeprüft nur, wo ein Fehler nichts kostet

Zwei offene Harnesses, der Einsatz entscheidet

OpenCode, der Allrounder

- Agent im Terminal, Modell je Agent
- LSP, Plugins, Skills, MCP
- oh-my-opencode: Routing, AST-Grep, Background-Agents
- Für tägliche Coding-Agents

pi, der Minimalist

- Skills, Prompt-Templates, Packages
- „Adapt pi, nicht umgekehrt“
- Für schlanke Setups mit voller Kontrolle

pi bleibt klein, alles andere kommt als Package

Kategorie	Beispiele
Skills	superpowers, CVE-Scanner, AGENTS.md-Audit
Agenten	subagents, until-done, plan-mode, evaluate
Stil, Werkzeuge, Suche	caveman, ponytail, mcp-Adapter, websearch
UI	webui, desktop-ui, glimpseui, chrome
Absicherung	tool-repair, retry, permissions, secrets, rtk

Pause.
Zehn Minuten.



Tobias

5

Hands-On: Erste Schritte

Erst planen, dann bauen

- Plan-Mode: der Agent liest, fragt und schlägt vor
- Nichts wird geändert, bis Sie zustimmen
- Build-Mode: der Agent setzt den freigegebenen Plan um
- Den Plan lesen ist der schnellste Weg zum Verständnis

Tobias

Übung 1: Ihr Thema X, direkt an den Agenten, fünfzehn Minuten

Der Agent übernimmt

Heißt konkret

Entdecken

neue Veröffentlichungen zu Thema X aufspüren

Einordnen


Funde den Themenfeldern zuordnen

Prüfen

Quellen verifizieren, Erfindungen aussortieren

Berichten

Überblick, Trends, Kurz-Briefings



Sie entscheiden, was relevant ist.
Der Agent übernimmt die Fleißarbeit.

Tobias

AGENTS.md: Regeln, die der Agent bei jedem Start liest

- Erzeugtes wird nie von Hand geändert
- Nichts wird erfunden, jede Quelle muss auflösbar sein
- Nach jeder Änderung die komplette Prüfung, dann Commit
- Geführt per Datei, nicht per Prompt

6

Vom Auftrag zur Spezifikation, und was sie an Token spart

In diesem Kapitel wird aus dem Auftrag eine Datei

- Eine Vorlage: ein fertiger Change zum Nachbauen
- Wo Spezifikation, Vertrag und Archiv liegen
- Spec-Kit oder OpenSpec: warum wir OpenSpec nehmen
- Warum eine präzise Spezifikation Token spart

Ein fertiger Change steht als Vorlage bereit

- Repo ai-literacy-research: über 9.600 Papers, 20 Kategorien
- openspec/specs/: Corpus, Discovery, Analyse
- Change add-research-gap-analysis: proposal, design, specs, tasks
- Gap-Score: $0,6 \times \text{Dünne} + 0,4 \times \text{Momentum} + \text{Floor-Bonus}$

Wo Spezifikation, Auftrag und Tests liegen

Ort	Was dort liegt	Rolle
openspec/specs/	das dauerhaft gültige Verhalten	Spezifikation
openspec/changes/	die eine anstehende Änderung	Vertrag, genau das bekommt der Agent
tests/	Prüfungen der Anforderungen	Tests, ausgeführt lokal oder in CI

Spec-Kit baut Neues, OpenSpec ändert Bestehendes

	Spec-Kit	OpenSpec
Grundidee	was gebaut werden soll	wie sich Bestehendes ändert
Typischer Fall	Neubau, neue Funktionen	laufende Weiterentwicklung
Quelle der Wahrheit	eine Spezifikation je Vorhaben	dauerhafte Spezifikation plus Änderungen
Ablauf	specify, clarify, plan, tasks	propose, apply, sync, archive
Aufwand	höher, mehr Prozessführung	niedriger

Token, Kosten und Qualität getrennt messen

- Routing: Kosten pro gelöster Aufgabe
- Caching: Berechnung wiederverwenden
- Kontext: nur Relevantes mitgeben
- Specs können Korrekturschleifen sparen
- Qualität an festen Kriterien prüfen

Christian

7


Hands-On: Mit Spec

Tobias

Jeder geht mit einem eigenen, CI-validierten Research-Repo

- Gleiche Frage wie in Übung 1, jetzt mit Spec
- Corpus: strukturierter Literaturbestand
- Regeln statt Handarbeit: prüfen, erzeugen, berichten
- Lebendig statt Momentaufnahme: CI prüft wöchentlich

In der Pipeline hat jede Stufe genau eine Aufgabe



- Ein Werkzeug, ein Job
- Text ist die Schnittstelle, für Mensch und Agent
- Grün heißt: definierte Checks bestanden

Der Jump-Start dauert fünf Schritte

- Kopie holen: das Demo-Repo wird Ihres
- Themenfeld setzen: Ihre Ordnung für Thema X
- Seeden: drei bis fünf Treffer aus Übung 1
- Laufen lassen: prüfen, erzeugen, berichten
- Veröffentlichen: das Ergebnis geht online

Christian

Übung 2: eine überprüfbare Anforderung für Ihr Thema

- Klein halten: eine Auswertung, eine Kennzahl
- Fertig: Tests bestanden, Ergebnis geprüft
- Mit Agent: erst /opsx-propose, dann /opsx-apply
- Ohne OpenSpec: dieselbe Struktur als Markdown

Übung 2 Schritt für Schritt, am Beispiel thema-x

Schritt	Eingabe	Ergebnis
1 · Terminal	<code>openspec init --tools opencode,pi</code>	Befehle und Skills für den Agenten
2 · Agent	<code>/opsx-propose thema-x: Papers pro Jahr als Kennzahl</code>	Proposal, Tasks und Spec
3 · Terminal	<code>openspec status --change thema-x</code>	welche Teile schon stehen
4 · Terminal	<code>openspec validate thema-x --strict</code>	Strukturprüfung der Spec
5 · Agent	<code>/opsx-apply thema-x</code>	der Agent arbeitet die Tasks ab
6 · Terminal	<code>openspec list</code>	Fortschritt, etwa 4/4 tasks
7 · Agent	<code>/opsx-archive thema-x</code>	die Spec wird fortgeschrieben

Schon das Mindestziel zeigt, dass die Methode sitzt

Ebene	Mindestziel	Vollständig
Spezifikation	ein Satz, der widerlegt werden kann	Szenario: Ausgangslage, Eingriff, Ergebnis
Vertrag	eine Aufgabenliste mit drei Punkten	Vorschlag, Entwurf, Spezifikation, Aufgaben
Tests	eine Prüfung, die fehlschlagen könnte	läuft automatisch und besteht

Pause.

Fünf Minuten.



Tobias

8

Outcomes: Ihre Ergebnisse

Gezeigt wird ein eigenes Repo mit eigenem Change

- Drei bis vier Freiwillige, je drei bis vier Minuten
- Pipeline grün, Change validiert, live oder als Screenshot
- Bewertet an der Pyramide: Spec, Change, grüner Check
- Das Publikum reviewt mit

Tobias

9

Ihre Anwendungsfälle, Q&A, Diskussion

So übertragen Sie das Muster auf eigene Projekte


- Klein starten: eine wiederkehrende Aufgabe, ein Prüfkriterium
- Den Auftrag als Datei: Spec, erster Change mit drei Tasks
- Checks bestehen, Ergebnis fachlich prüfen
- Instruktionen und Skills anlegen statt jedes Mal erklären
- Erkenntnisse aus dem Betrieb werden neue Changes

Die Werkzeuge des Vormittags zum Nachinstallieren

Werkzeug	Adresse
OpenCode	github.com/sst/opencode
pi	pi.dev
zot	zot.sh
OpenSpec	npmjs.com/package/@fission-ai/openspec
SAIA-Plugin für pi	codeberg.org/tobias-weiss-ai-xr/pi-saia-plugin
SAIA-Plugin für OpenCode	github.com/tobias-weiss-ai-xr/opencode-saia-plugin
oh-my-opencode	github.com/code-yeongyu/oh-my-opencode

Repositories und Skills zum Weiterarbeiten

Name	Adresse
skeleton-research	github.com/tobias-weiss-ai-xr/skeleton-research
ai-literacy-research	github.com/tobias-weiss-ai-xr/ai-literacy-research
Superpowers	github.com/obra/superpowers
rtk	github.com/rtk-ai/rtk
ponytail	github.com/DietrichGebert/ponytail
caveman	github.com/JuliusBrussee/caveman



Vielen Dank!

Fragen gern als GitHub-Issue.

CC BY 4.0 · Christian Uhl · Tobias Weiß

Quellen und Links

- [1] Model Context Protocol — <https://modelcontextprotocol.io>
- [2] Agent Skills Specification — <https://agentskills.io/specification>
- [3] OpenCode Skills — <https://opencode.ai/docs/skills/>
- [4] pi Skills — <https://pi.dev/docs/latest/skills>
- [5] Snyk ToxicSkills, 02/2026 — <https://snyk.io/blog/toxicskills-malicious-ai-agent-skills-clawhub/>
- [6] Gemini Deep Research — <https://gemini.google/de/overview/deep-research/>
- [7] Microsoft 365 Copilot Researcher — <https://learn.microsoft.com/en-us/copilot/microsoft-365/faq-researcher>
- [8] Claude in Chrome — <https://claude.com/blog/claude-in-chrome-generally-available>
- [9] Alexa+ in Deutschland — <https://www.teltarif.de/en/alexaplus-deutschland-amazon/news/103392.html>
- [10] Elicit Research Agent — <https://elicit.com/blog/introducing-research-agent-workflows>
- [11] Google Co-Scientist — <https://deepmind.google/blog/co-scientist-a-multi-agent-ai-partner-to-accelerate-research/>
- [12] Arena Vision Leaderboard, Stand 28.09.2026 — <https://arena.ai/leaderboard/vision>
- [13] Ewerlöf, Coding is NOT Solved, 26.09.2026 — <https://blog.alexewerlof.com/p/coding-is-not-solved>
- [14] 26 Packages, eigene Installation, Stand 09/2026 — <https://pi.dev/packages>
- [15] GitHub Spec Kit — <https://github.com/github/spec-kit>
- [16] Fission AI OpenSpec — <https://github.com/Fission-AI/OpenSpec>
- [17] Prompt Caching — <https://developers.openai.com/api/docs/guides/prompt-caching>
- [18] OpenSpec 1.13.2, CLI-Referenz — <https://github.com/Fission-AI/OpenSpec/blob/main/docs/cli.md>
- [19] OpenCode — <https://github.com/sst/opencode>
- [20] pi — <https://pi.dev>
- [21] zot — <https://zot.sh>

Quellen und Links (2)

- [22] OpenSpec — <https://www.npmjs.com/package/@fission-ai/openspec>
- [23] pi-saia-plugin — <https://codeberg.org/tobias-weiss-ai-xr/pi-saia-plugin>
- [24] opencode-saia-plugin — <https://github.com/tobias-weiss-ai-xr/opencode-saia-plugin>
- [25] oh-my-opencode — <https://github.com/code-yeongyu/oh-my-opencode>
- [26] skeleton-research — <https://github.com/tobias-weiss-ai-xr/skeleton-research>
- [27] ai-literacy-research — <https://github.com/tobias-weiss-ai-xr/ai-literacy-research>
- [28] Superpowers — <https://github.com/obra/superpowers>
- [29] rtk — <https://github.com/rtk-ai/rtk>
- [30] ponytail — <https://github.com/DietrichGebert/ponytail>
- [31] caveman — <https://github.com/JuliusBrussee/caveman>